Name: Anik Manik

Email address: iamanik4@gmail.com

**Contact number: 9477672426** 

Anydesk address: 400 728 410

Years of Work Experience: 2.6 years

drive.mount('gdrive',force\_remount=True)

Mounted at gdrive

**Date: 24th Jan 2021** 

```
In [1]: import warnings
        warnings.filterwarnings("ignore")
        import matplotlib.pyplot as plt
        import seaborn as sns
        import numpy as np
        import os
        import datetime as dt
        from datetime import datetime
        from tqdm.notebook import tqdm
        from glob import glob
        import pandas as pd
        import shutil
        import glob2
        from tensorflow.keras import models, layers
        from tensorflow.keras.models import Model
        from tensorflow.keras.layers import BatchNormalization, Activation, Flatten
        from tensorflow.keras.optimizers import Adam
        from tensorflow.keras.callbacks import *
        from tensorflow.keras.layers import *
        from tensorflow.keras.models import Model
        import datetime
        from sklearn.model selection import train test split
        from keras.losses import binary_crossentropy
        import keras.backend as K
        from keras.models import load model
In [2]: # install libraries to read dicom images
        !pip install -q tensorflow-io
        !pip install pydicom
                                              | 25.3MB 128kB/s
        Collecting pydicom
          Downloading https://files.pythonhosted.org/packages/f4/15/df16546bc59bfca390cf072d473fb2c8acd423163
        6f6435<u>6593a63137e55/pydicom-2.1.2-py3-</u>none-any.whl (1.9MB)
                                               1.9MB 18.8MB/s
        Installing collected packages: pydicom
        Successfully installed pydicom-2.1.2
In [3]: import pydicom as dicom
        import tensorflow as tf
        import tensorflow_io as tfio
In [4]: # mount google drive
        from google.colab import drive
```

### Download the dataset from kaggle

2

3

1.2.276.0.7230010.3.1.4.8323329.11028.15178752...

1.2.276.0.7230010.3.1.4.8323329.10366.15178752...

1.2.276.0.7230010.3.1.4.8323329.10016.15178752...

#### https://www.kaggle.com/seesee/siim-train-test (https://www.kaggle.com/seesee/siim-train-test)

```
In [5]: # download the dataset from kagale
        # https://www.kaaale.com/seesee/siim-train-test
        !wget --header="Host: storage.googleapis.com" --header="User-Agent: Mozilla/5.0 (Windows NT 10.0; Win6
       4; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/89.0.4389.90 Safari/537.36" --header="Accept: te
       xt/html,application/xhtml+xml,application/xml;q=0.9,image/avif,image/webp,image/appg,*/*;q=0.8,applica
       tion/signed-exchange;v=b3;q=0.9" --header="Accept-Language: en-US,en;q=0.9" --header="Referer: http
       s://www.kaggle.com/" --header="Cookie: ext name=ojplmecpdpgccookcobabopnaifgidhf" --header="Connectio
       n: keep-alive" "https://storage.googleapis.com/kaggle-data-sets/245622/651264/bundle/archive.zip?X-Goo
       g-Algorithm=GOOG4-RSA-SHA256&X-Goog-Credential=gcp-kaggle-com%40kaggle-161607.iam.gserviceaccount.com%
        2F20210324%2Fauto%2Fstorage%2Fgoog4 request&X-Goog-Date=20210324T022759Z&X-Goog-Expires=259199&X-Goog-
       SignedHeaders=host&X-Goog-Signature=6537e07b49380396cf2a8773c646d3e4847a77f3f9e6d24612c369ee3962e3aaab
       5e69f6e9ea89f09026dea49c0ea2818d9a29f5e713e0b25cba7445cbfe806668b81034ec3b93f88942ec5770e0e69c7c2387a4
       fcc6ea770aa548f4e84d1e7f7d789e8581e5a78883165555fc729dbfeeeca80c797157680c411dd8e045b95a5eb7b304d91f89
       f4e56a9bc25d46f84a416d540b4aef097d7ac0512bcc6ca52495e135a86065aaec9e9fe7f0188a29d89f1c11775b84f8d64d8b
       492927c1ec7296b0f9828950b2ffe6f6a12e76" -c -0 'archive.zip'
       --2021-03-24 12:48:55-- https://storage.googleapis.com/kaggle-data-sets/245622/651264/bundle/archiv
       e.zip?X-Goog-Algorithm=GOOG4-RSA-SHA256&X-Goog-Credential=gcp-kaggle-com%40kaggle-161607.iam.gservice
       account.com%2F20210324%2Fauto%2Fstorage%2Fgoog4_request&X-Goog-Date=20210324T022759Z&X-Goog-Expires=2
       59199&X-Goog-SignedHeaders=host&X-Goog-Signature=6537e07b49380396cf2a8773c646d3e4847a77f3f9e6d24612c3
       69ee3962e3aaab5e69f6e9ea89f09026dea49c0ea2818d9a29f5e713e0b25cba7445cbfe806668b81034ec3b93f88942ec577
       0e0e69c7c2387a4fcc6ea770aa548f4e84d1e7f7d789e8581e5a78883165555fc729dbfeeeca80c797157680c411dd8e045b9
       5a5eb7b304d91f89f4e56a9bc25d46f84a416d540b4aef097d7ac0512bcc6ca52495e135a86065aaec9e9fe7f0188a29d89f1
       438bc2a538c77d0fb9492927c1ec7296b0f9828950b2ffe6f6a12e76
       Resolving storage.googleapis.com (storage.googleapis.com)... 172.217.7.176, 172.217.7.208, 172.217.1
       5.112. ...
       Connecting to storage.googleapis.com (storage.googleapis.com)|172.217.7.176|:443... connected.
       HTTP request sent, awaiting response... 200 OK
       Length: 2059765561 (1.9G) [application/zip]
       Saving to: 'archive.zip'
       archive.zip
                          in 19s
       2021-03-24 12:49:14 (101 MB/s) - 'archive.zip' saved [2059765561/2059765561]
In [6]: # unzip the dataset
        !unzip -qq 'archive.zip'
In [7]:
       # read the given train csv file
        image df = pd.read csv('siim/train-rle.csv')
        image_df.head()
Out[7]:
                                            Imageld
                                                                               EncodedPixels
          1.2.276.0.7230010.3.1.4.8323329.6904.151787520...
          1.2.276 0.7230010 3.1.4 8323329 13666 15178752
                                                   557374 2 1015 8 1009 14 1002 20 997 26 990 32 ...
```

```
In [8]: # drop the duplicate ImageIDs
  image_df.drop_duplicates(subset ="ImageId", keep = 'first', inplace = True)
```

-1

514175 10 1008 29 994 30 993 32 991 33 990 34 ..

592184 33 976 58 956 73 941 88 926 102 917 109...

```
In [9]: # create a directory for dicom images
images_dicom = 'siim/images_dicom/'
if not os.path.isdir(images_dicom):
    os.makedirs(images_dicom)

# move all train dicom images from 'dicom-images-train' to 'images_dicom' in a single directory
existing_path = 'siim/dicom-images-train/'
dicom_list = glob2.glob(os.path.join(existing_path, '**/*.dcm'))
for filename in tqdm(dicom_list):
    shutil.move(str(filename), images_dicom)
```

```
In [10]: # remove extra space in EncodedPixels column
  image_df.rename(columns = {' EncodedPixels':'EncodedPixels'}, inplace = True)

# add a column whether the image is with pneumothorax or without pneumothorax
  image_df['is_pneumothorax'] = np.where(image_df['EncodedPixels']=='-1', 0, 1)
  image_df.head()
```

Out[10]:

	Imageld	EncodedPixels	is_pneumothorax
0	1.2.276.0.7230010.3.1.4.8323329.6904.151787520	-1	0
1	1.2.276.0.7230010.3.1.4.8323329.13666.15178752	557374 2 1015 8 1009 14 1002 20 997 26 990 32	1
2	1.2.276.0.7230010.3.1.4.8323329.11028.15178752	-1	0
3	1.2.276.0.7230010.3.1.4.8323329.10366.15178752	514175 10 1008 29 994 30 993 32 991 33 990 34	1
4	1.2.276.0.7230010.3.1.4.8323329.10016.15178752	592184 33 976 58 956 73 941 88 926 102 917 109	1

```
In [11]: # split the dataset and use val_df for final prediction
    from sklearn.model_selection import train_test_split
    train_df, val_df = train_test_split(image_df, test_size=0.2, random_state=42, stratify=image_df['is_pn eumothorax'], shuffle=True)
```

```
In [12]: # add full dicom path to image_df
    val_df['dicom_path'] = images_dicom + val_df['ImageId']+'.dcm'
    val_df.head()
```

Out[12]:

	Imageld	EncodedPixels	is_pneumothorax	
10812	1.2.276.0.7230010.3.1.4.8323329.11636.15178752	-1	0	siim/images_dicom/1.2.27
7110	1.2.276.0.7230010.3.1.4.8323329.4471.151787518	278724 1 1020 6 1016 9 1014 11 1011 13 1010 13	1	siim/images_dicom/1.2.27
5130	1.2.276.0.7230010.3.1.4.8323329.5233.151787518	-1	0	siim/images_dicom/1.2.27
5131	1.2.276.0.7230010.3.1.4.8323329.11260.15178752	611609 30 992 33 989 36 987 40 982 44 978 49 9	1	siim/images_dicom/1.2.27
5297	1.2.276.0.7230010.3.1.4.8323329.14511.15178752	-1	0	siim/images_dicom/1.2.27

```
In [13]: from keras.models import load_model
    model_2 = load_model("gdrive/My Drive/Colab Notebooks/cs2_pneumothorax/classification/weights-07-0.640
    0.hdf5")
```

## Calculate the predicted probabilities from the classification model

```
In [14]: val_image_path = val_df['dicom_path'].values
    val_image_prob = []
    for file in tqdm(val_image_path):
        size = 256
        image = tf.io.read_file(file)
        image = tfio.image.decode_dicom_image(image, dtype=tf.uint8,color_dim=True,scale='preserve')
        image = tf.image.convert_image_dtype(image, tf.float32)
        image = tf.squeeze(image,[0])
        image=tf.tile(image, tf.constant([1,1,3], tf.int32))
        image=tf.image.resize(image,size=[size,size])
        image = tf.expand_dims(image,axis=0)

        pred = model_2.predict(image)
        val_image_prob.append(pred[0])
```

## Define function to plot confusion matrix

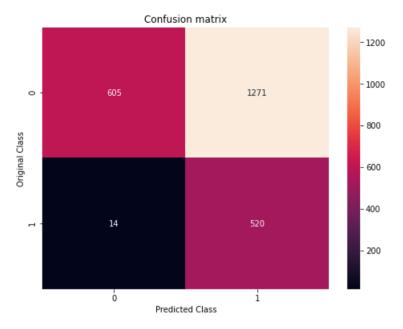
```
In [15]:
    from sklearn.metrics import confusion_matrix
    # define function to plot confusion matrix
    def conf_matrix(test_y,predict_y):
        labels = [0,1]
        plt.figure(figsize=(8,6))
        C = confusion_matrix(test_y, predict_y)
        Precision = C[1][1]/(C[0][1] + C[1][1])
        Recall = C[1][1]/(C[1][0] + C[1][1])
        sns.heatmap(C, annot=True, fmt='d')
        plt.xlabel('Predicted Class')
        plt.ylabel('Original Class')
        plt.title('Confusion matrix')
        plt.show()
        return Precision, Recall
```

### Plot Confusion Matrix for different thresholds

```
In [16]:
    val_image_label = val_df['is_pneumothorax'].values
    threshold_list = [0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9]
    # threshold_list = [0.5]
    for threshold in threshold_list:
        val_pred_label = []
        for ele in val_image_prob:
        if ele > threshold:
            val_pred_label.append(1)
        else:
            val_pred_label.append(0)

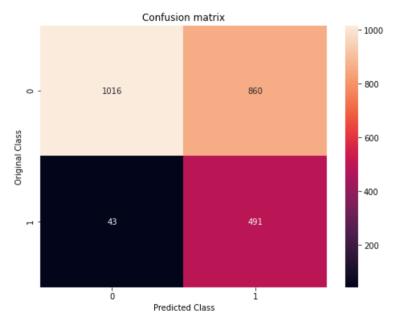
        print("\n\n" + "="*20 + " Threshold Value = " + str(threshold) + " " + "="*20)
        Precision, Recall = conf_matrix(val_image_label, val_pred_label)
        print("Precision = {:.4f}, Recall = {:.4f} for Threshold = {}".format(Precision, Recall, threshold))
```

=========== Threshold Value = 0.1 ==========



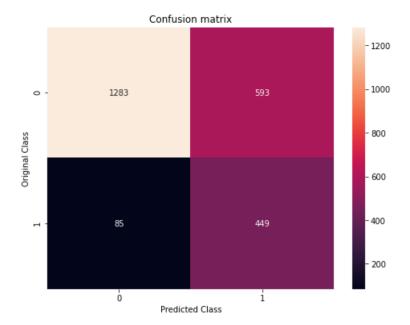
Precision = 0.2903, Recall = 0.9738 for Threshold = 0.1

========== Threshold Value = 0.2 ==========

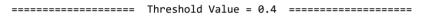


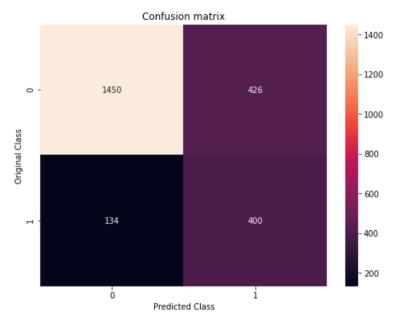
Precision = 0.3634, Recall = 0.9195 for Threshold = 0.2

========= Threshold Value = 0.3 ==========



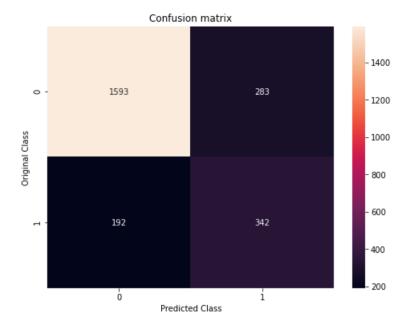
Precision = 0.4309, Recall = 0.8408 for Threshold = 0.3



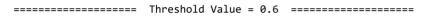


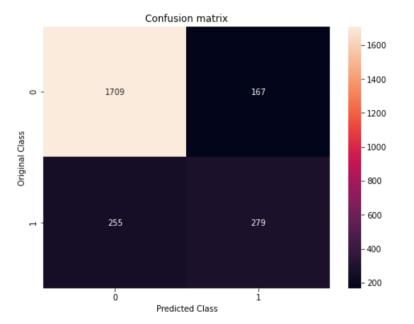
Precision = 0.4843, Recall = 0.7491 for Threshold = 0.4

========== Threshold Value = 0.5 ===========



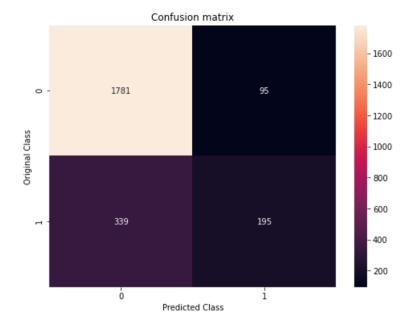
Precision = 0.5472, Recall = 0.6404 for Threshold = 0.5



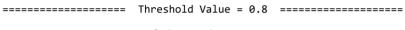


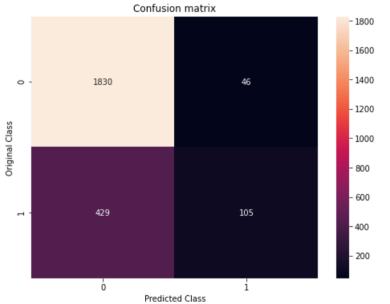
Precision = 0.6256, Recall = 0.5225 for Threshold = 0.6

========= Threshold Value = 0.7 ===========



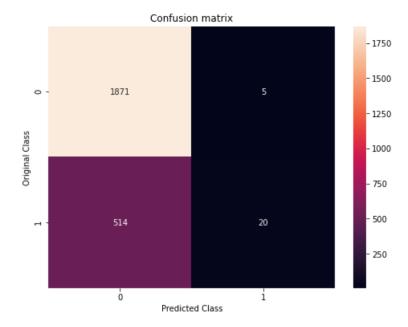
Precision = 0.6724, Recall = 0.3652 for Threshold = 0.7





Precision = 0.6954, Recall = 0.1966 for Threshold = 0.8

========= Threshold Value = 0.9 ===========



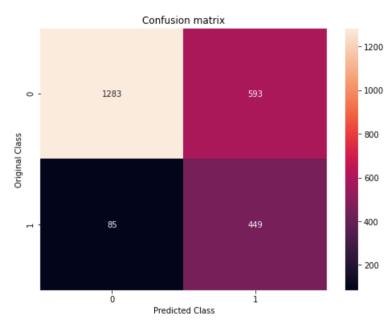
Precision = 0.8000, Recall = 0.0375 for Threshold = 0.9

Looking at all the confusion matrix, we can see that for threshold = 0.1 recall is very high but precision is very low. Considering both precision and recall, I am taking 0.3 as final threshold.

## Predict labels based on the threshold value

```
In [17]: threshold = 0.3
    val_pred_label = []
    for ele in val_image_prob:
        if ele > threshold:
            val_pred_label.append(1)
        else:
            val_pred_label.append(0)
# print(confusion_matrix(val_image_label, val_pred_label))
print("\n\n" + "="*20 + " Threshold Value = " + str(threshold) + " " + "="*20)
Precision, Recall = conf_matrix(val_image_label, val_pred_label)
print("Precision = {:.4f}, Recall = {:.4f} for Threshold = {}".format(Precision, Recall, threshold))
```

======== Threshold Value = 0.3 ==========



Precision = 0.4309, Recall = 0.8408 for Threshold = 0.3

```
In [18]: # add a new column in val_df dataframe with the predicted probabilities and predicted classes
  val_image_prob = [ele[0] for ele in val_image_prob]
  val_df['pred_prob'] = val_image_prob
  val_df['pred_label'] = val_pred_label
  val_df.head()
```

Out[18]:

	Imageld	EncodedPixels	is_pneumothorax	
10812	1.2.276.0.7230010.3.1.4.8323329.11636.15178752	-1	0	siim/images_dicom/1.2.27
7110	1.2.276.0.7230010.3.1.4.8323329.4471.151787518	278724 1 1020 6 1016 9 1014 11 1011 13 1010 13	1	siim/images_dicom/1.2.27
5130	1.2.276.0.7230010.3.1.4.8323329.5233.151787518	-1	0	siim/images_dicom/1.2.27
5131	1.2.276.0.7230010.3.1.4.8323329.11260.15178752	611609 30 992 33 989 36 987 40 982 44 978 49 9	1	siim/images_dicom/1.2.27
5297	1.2.276.0.7230010.3.1.4.8323329.14511.15178752	-1	0	siim/images_dicom/1.2.27

In [19]: # save val\_df for future use
 val\_df.to\_csv('gdrive/My Drive/Colab Notebooks/cs2\_pneumothorax/classification/val\_df\_with\_prob.csv',
 index=False)

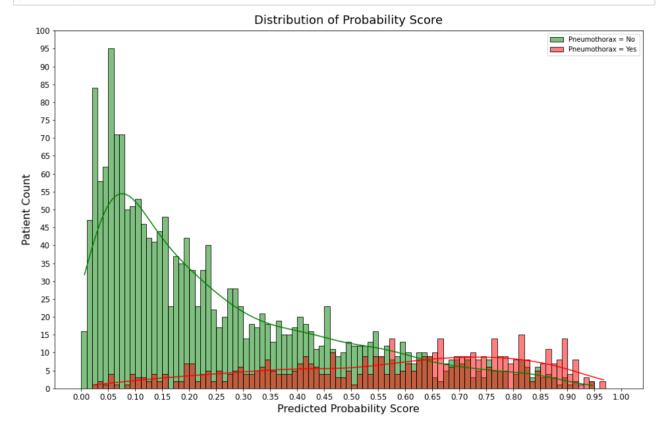
In [20]: # load val\_df from drive
 val\_df = pd.read\_csv('gdrive/My Drive/Colab Notebooks/cs2\_pneumothorax/classification/val\_df\_with\_pro
 b.csv')
 val\_df.head()

Out[20]:

	Imageld	EncodedPixels	is_pneumothorax	
0	1.2.276.0.7230010.3.1.4.8323329.11636.15178752	-1	0	siim/images_dicom/1.2.276.0.7
1	1.2.276.0.7230010.3.1.4.8323329.4471.151787518	278724 1 1020 6 1016 9 1014 11 1011 13 1010 13	1	siim/images_dicom/1.2.276.0.7
2	1.2.276.0.7230010.3.1.4.8323329.5233.151787518	-1	0	siim/images_dicom/1.2.276.0.7
3	1.2.276.0.7230010.3.1.4.8323329.11260.15178752	611609 30 992 33 989 36 987 40 982 44 978 49 9	1	siim/images_dicom/1.2.276.0.7
4	1.2.276.0.7230010.3.1.4.8323329.14511.15178752	-1	0	siim/images_dicom/1.2.276.0.7

# Distribution of predicted probability score

```
In [65]: # plot the distribution of the predicted probability score
plt.figure(figsize=(16, 10))
probability = [i/100 for i in range(100)]
sns.histplot(val_df[(val_df.is_pneumothorax == 0)]['pred_prob'], bins=[i for i in probability], color=
"green", kde=True, label="Pneumothorax = No")
sns.histplot(val_df[(val_df.is_pneumothorax == 1)]['pred_prob'], bins=[i for i in probability], color=
"red", kde=True, label="Pneumothorax = Yes")
plt.xticks([i/20 for i in range(21)], size = 12)
plt.yticks([i*5 for i in range(21)], size = 12)
plt.title("Distribution of Probability Score", fontsize=18, pad=10)
plt.xlabel("Predicted Probability Score", fontsize=16)
plt.ylabel("Patient Count", fontsize=16)
plt.legend()
plt.show()
```



### **Conclusion:**

- 1. There is a overlap between the probability scores of positive and negative points.
- 2. As per the distribution 0.65 is the best threshold but we have taken 0.3 as threshold because patients which contains pneumothorax is our main concern. It is okay to predict a patient without pneumothorax as pneumothorax but the opposite can be dangerous.

## **False Negative Analysis**

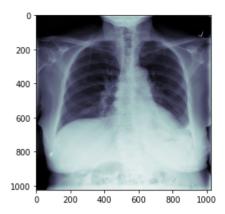
In [33]: # put false negative points in false\_negative\_val\_df
false\_negative\_val\_df = val\_df[(val\_df["is\_pneumothorax"]==1) & (val\_df["pred\_label"]==0)]
false\_negative\_val\_df = false\_negative\_val\_df.sort\_values(by=['pred\_prob'], ascending=True) false\_negative\_val\_df.head()

Out[33]:

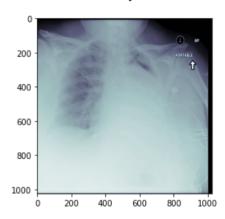
	Imageld	EncodedPixels	is_pneumothorax	
2194	1.2.276.0.7230010.3.1.4.8323329.10336.15178752	642202 9 1014 11 1013 12 1011 13 1011 13 1010	1	siim/images_dicom/1.2.276
453	1.2.276.0.7230010.3.1.4.8323329.4735.151787518	551095 2 1019 9 1013 13 1008 19 1003 22 1000 2	1	siim/images_dicom/1.2.276
1452	1.2.276.0.7230010.3.1.4.8323329.1339.151787516	594107 3 1015 13 1010 15 1008 17 1006 19 1004	1	siim/images_dicom/1.2.276
267	1.2.276.0.7230010.3.1.4.8323329.4469.151787518	634025 12 1010 18 1004 22 1001 24 998 26 997 2	1	siim/images_dicom/1.2.276
382	1.2.276.0.7230010.3.1.4.8323329.31865.15178751	378947 1 1022 1 1023 1 1022 2 1022 1 1023 1 10	1	siim/images_dicom/1.2.276

```
In [66]: # displaying first 10 images with least probability score from false_negative_val_df
for image_row in range(0,10):
    sample_img = dicom.read_file(false_negative_val_df['dicom_path'].iloc[image_row]).pixel_array
    print('ImageId = '+str(false_negative_val_df['dicom_path'].iloc[image_row]))
    print("Original Class = 1 and Predicted Class = 0")
    print('Predicted Probability = ' + str(false_negative_val_df['pred_prob'].iloc[image_row]))
    plt.imshow(sample_img, cmap='bone')
    plt.show()
    print('\n\n')
```

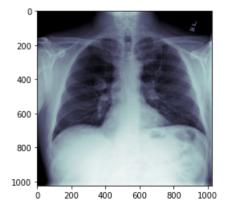
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.10336.1517875223.220220.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.02580205164849758



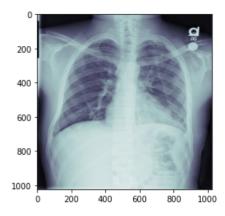
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.4735.1517875184.410483.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.03687261417508125



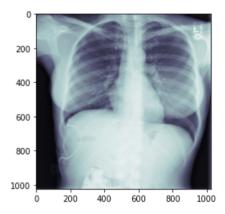
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.1339.1517875167.304186.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.03993135690689087



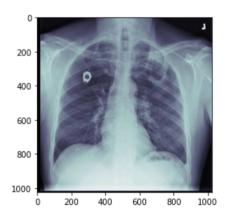
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.4469.1517875183.18796.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.04197678342461586



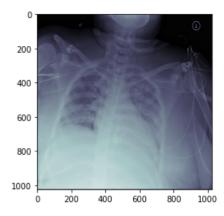
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.31865.1517875157.209292.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.050168614834547036



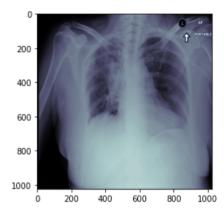
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.11990.1517875236.793020.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.05123323202133179



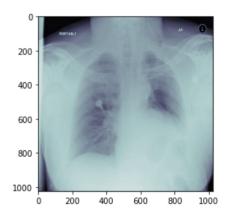
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.3209.1517875176.611814.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.057887747883796685



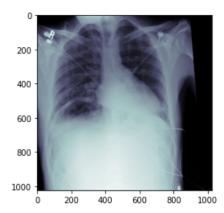
 $\label{local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_loc$ 



 $\label{localization} ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.2320.1517875172.159451.dcm \\ Original Class = 1 and Predicted Class = 0 \\ Predicted Probability = 0.06254734098911285$ 

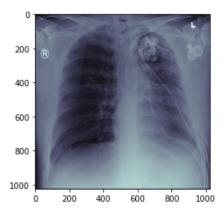


ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.12323.1517875238.576790.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.08710384368896484

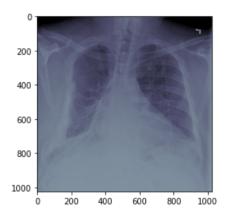


```
In [67]: # displaying last 10 images with max probability score from false_negative_val_df
for image_row in range(len(false_negative_val_df)-10, len(false_negative_val_df)):
    sample_img = dicom.read_file(false_negative_val_df['dicom_path'].iloc[image_row]).pixel_array
    print('ImageId = '+str(false_negative_val_df['dicom_path'].iloc[image_row]))
    print("Original Class = 1 and Predicted Class = 0")
    print('Predicted Probability = ' + str(false_negative_val_df['pred_prob'].iloc[image_row]))
    plt.imshow(sample_img, cmap='bone')
    plt.show()
    print('\n\n')
```

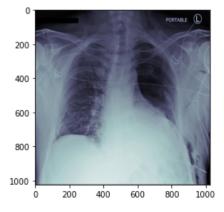
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.10374.1517875223.421330.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.2867679297924042



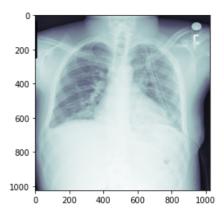
 $\label{localization} ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.3125.1517875176.223801.dcm \\ Original Class = 1 and Predicted Class = 0 \\ Predicted Probability = 0.28812387585639954$ 



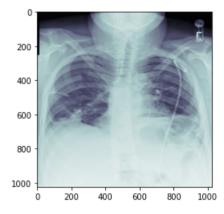
 $\label{localization} ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.3123.1517875176.214943.dcm \\ Original Class = 1 and Predicted Class = 0 \\ Predicted Probability = 0.288391649723053$ 



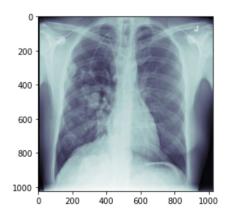
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.12097.1517875237.372856.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.2897959053516388



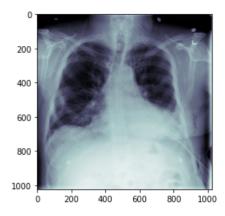
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.1677.1517875168.880742.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.2902456521987915



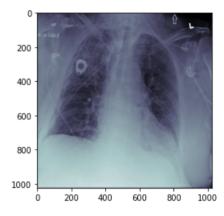
 $\label{localization} ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.4429.1517875182.835395.dcm \\ Original Class = 1 and Predicted Class = 0 \\ Predicted Probability = 0.29037055373191833$ 



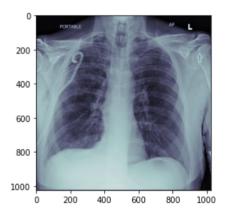
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.4958.1517875185.686212.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.29176196455955505



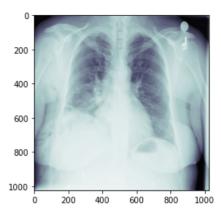
 $\label{localization} ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.12422.1517875239.46167.dcm \\ Original Class = 1 and Predicted Class = 0 \\ Predicted Probability = 0.2923955023288727$ 



ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.5202.1517875186.940296.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.295212596654892



ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.10094.1517875221.969850.dcm
Original Class = 1 and Predicted Class = 0
Predicted Probability = 0.2954666018486023



## **Conclusion:**

- 1. False negative points whose pobability score are very low(near zero), are classified completely wrongly. To fix this issue we need to oversample these data so that the model can learn from this similar images.
- 2. False negative points whose probability score is less than threshold but has little higher value(near about threshold value), even though these are classified wrongly this can be fixed by traing our model furthermore.

## **False Positive Analysis**

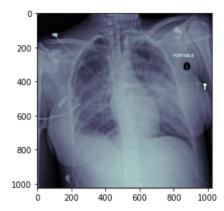
In [34]: # put false positive points in false\_positive\_val\_df
false\_positive\_val\_df = val\_df[(val\_df["is\_pneumothorax"]==0) & (val\_df["pred\_label"]==1)]
false\_positive\_val\_df = false\_positive\_val\_df.sort\_values(by=['pred\_prob'], ascending=True)
false\_positive\_val\_df.head()

Out[34]:

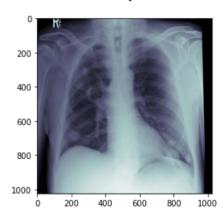
	Imageld	EncodedPixels	is_pneumothorax	
1750	1.2.276.0.7230010.3.1.4.8323329.3439.151787517	-1	0	siim/images_dicom/1.2.276
482	1.2.276.0.7230010.3.1.4.8323329.5928.151787519	-1	0	siim/images_dicom/1.2.276
134	1.2.276.0.7230010.3.1.4.8323329.14318.15178752	-1	0	siim/images_dicom/1.2.276
1748	1.2.276.0.7230010.3.1.4.8323329.31775.15178751	-1	0	siim/images_dicom/1.2.276
2067	1.2.276.0.7230010.3.1.4.8323329.1037.151787516	-1	0	siim/images_dicom/1.2.276

```
In [68]: # displaying first 10 images with least probability score from false_positive_val_df
for image_row in range(0,10):
    sample_img = dicom.read_file(false_positive_val_df['dicom_path'].iloc[image_row]).pixel_array
    print('ImageId = '+str(false_positive_val_df['dicom_path'].iloc[image_row]))
    print("Original Class = 0 and Predicted Class = 1")
    print('Predicted Probability = ' + str(false_positive_val_df['pred_prob'].iloc[image_row]))
    plt.imshow(sample_img, cmap='bone')
    plt.show()
    print('\n\n')
```

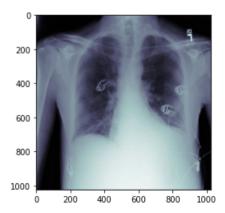
 $\label{localization} ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.3439.1517875177.852416.dcm \\ Original Class = 0 and Predicted Class = 1 \\ Predicted Probability = 0.3001985251903534$ 



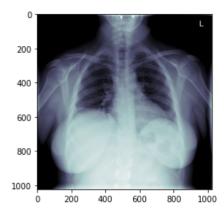
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.5928.1517875192.727858.dcm
Original Class = 0 and Predicted Class = 1
Predicted Probability = 0.3003208935260773



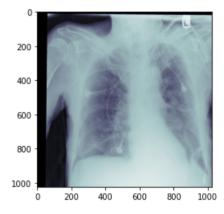
 $\label{local_local_local_local_local_local} ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.14318.1517875251.231260.dcm \\ Original Class = 0 and Predicted Class = 1 \\ Predicted Probability = 0.3013767004013061 \\$ 



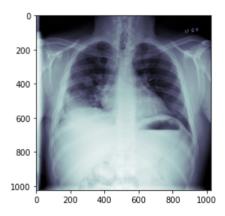
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.31775.1517875156.777338.dcm
Original Class = 0 and Predicted Class = 1
Predicted Probability = 0.3015292286872864



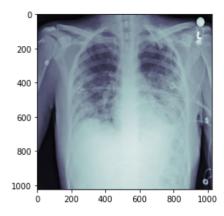
 $\label{local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_loc$ 



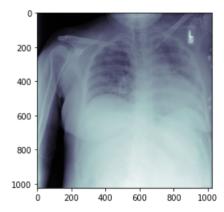
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.10189.1517875222.538484.dcm
Original Class = 0 and Predicted Class = 1
Predicted Probability = 0.30243226885795593



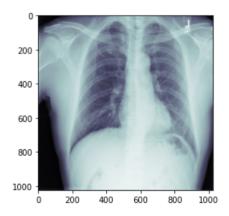
 $\label{localization} ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.1576.1517875168.475041.dcm \\ Original Class = 0 and Predicted Class = 1 \\ Predicted Probability = 0.30267927050590515$ 



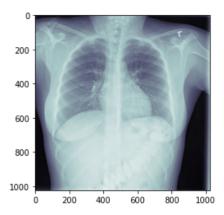
 $\label{local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_loc$ 



ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.1257.1517875166.994874.dcm
Original Class = 0 and Predicted Class = 1
Predicted Probability = 0.3031831979751587

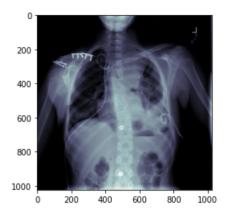


ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.32266.1517875159.299328.dcm
Original Class = 0 and Predicted Class = 1
Predicted Probability = 0.30321142077445984

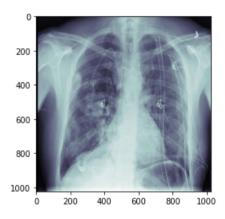


```
In [69]: # displaying last 10 images with max probability score from false_positive_val_df
for image_row in range(len(false_positive_val_df)-10, len(false_positive_val_df)):
    sample_img = dicom.read_file(false_positive_val_df['dicom_path'].iloc[image_row]).pixel_array
    print('ImageId = '+str(false_positive_val_df['dicom_path'].iloc[image_row]))
    print("Original Class = 0 and Predicted Class = 1")
    print('Predicted Probability = ' + str(false_positive_val_df['pred_prob'].iloc[image_row]))
    plt.imshow(sample_img, cmap='bone')
    plt.show()
    print('\n\n')
```

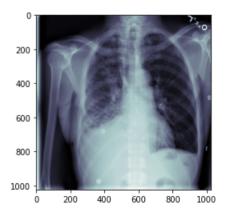
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.3344.1517875177.387601.dcm
Original Class = 0 and Predicted Class = 1
Predicted Probability = 0.8747736811637878



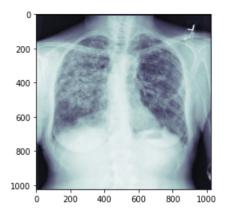
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.13401.1517875245.151502.dcm
Original Class = 0 and Predicted Class = 1
Predicted Probability = 0.885296106338501



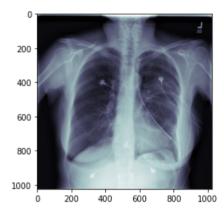
 $\label{local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_loc$ 



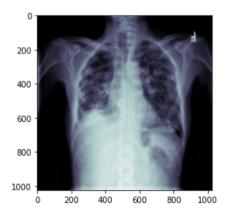
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.12625.1517875240.194497.dcm
Original Class = 0 and Predicted Class = 1
Predicted Probability = 0.8977672457695007



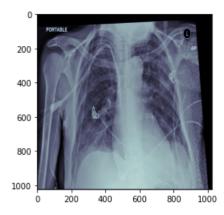
 $\label{local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_loc$ 



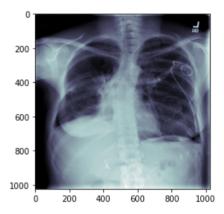
ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.5609.1517875189.27613.dcm
Original Class = 0 and Predicted Class = 1
Predicted Probability = 0.9007509350776672



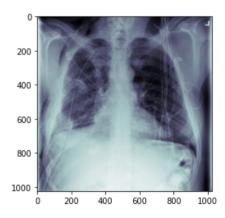
 $\label{localization} ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.6450.1517875198.300471.dcm \\ Original Class = 0 and Predicted Class = 1 \\ Predicted Probability = 0.910106360912323$ 



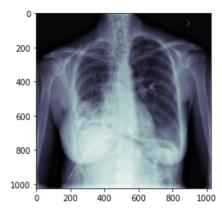
 $\label{local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_loc$ 



ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.31670.1517875156.225110.dcm
Original Class = 0 and Predicted Class = 1
Predicted Probability = 0.940726399421692



 $\label{localization} ImageId = siim/images\_dicom/1.2.276.0.7230010.3.1.4.8323329.4863.1517875185.163456.dcm \\ Original Class = 0 and Predicted Class = 1 \\ Predicted Probability = 0.9462146162986756$ 



# **Conclusion:**

- 1. False positive points whose probability score is higher(near one), are classified complete wrongly. We need to oversample these data and train our model to get better result.
- 2. False positive points whose probability score is lower(near threshold value) but higher than the threshold, even though these points are classified wrongly this can be fixed by training our model further.